

Informe de Resultados

Fecha de entrega:

21 de julio de 2026

Integrante/s:

- Carlos Daniel Corrales Arango (2122878)

Tema o actividad asignada:

Informe de resultados sobre la línea de investigación retomada del Semillero GUIA: evaluación de la capacidad predictiva de la estructura de red small-world de la sismicidad colombiana ([Link](#))

Descripción del avance

Este trabajo retoma una línea de investigación del semillero: el modelado de la sismicidad colombiana como una red compleja tridimensional, a partir del artículo base de León-Vargas, Bucheli-Guerrero y Ordoñez-Erazo (2023), "Modelado de la sismicidad colombiana como una red compleja espacio-secuencial". El objetivo planteado fue evaluar si la estructura de pequeño mundo (small-world) identificada en dicho artículo contiene información explotable para predecir el próximo nodo de actividad sísmica, comparando tres familias de modelos de complejidad creciente.

El trabajo se desarrolló en cuatro fases:

1. **Auditoría de la base de datos heredada:** se verificó qué correspondía exactamente al artículo original y qué material adicional existía sin documentar, reconstruyendo además la secuencia real nodo-a-nodo a partir de miles de archivos de ventanas temporales.
2. **Preparación de datos y partición temporal:** construcción de un pipeline reproducible en Google Colab, con partición 70/15/15 estrictamente cronológica (sin mezclar eventos al azar) para evitar fuga de información del futuro al pasado.
3. **Modelado comparativo:** implementación y evaluación de tres enfoques, primero un modelo probabilístico de transición (cadena de Markov), segundo un modelo secuencial con mecanismo de atención, y un modelo estructural de grafos (GNN) que incorpora geografía, profundidad y topología de la red.
4. **Consolidación y discusión honesta de resultados,** incluyendo hallazgos negativos.

Desarrollo o metodología

Antes de modelar fue necesario entender a fondo el fenómeno físico detrás de los datos: qué es un sismo, por qué la magnitud se comporta en escala logarítmica (ley de Gutenberg-Richter), y por qué Colombia al ubicarse en el cruce de cinco placas tectónicas presenta una zona de concentración sísmica excepcional conocida como el nido sísmico de Bucaramanga. Este contexto resultó indispensable para interpretar correctamente los resultados cuantitativos obtenidos más adelante.

La metodología técnica siguió estos pasos:

- Se auditaron 8 archivos CSV agregados y, posteriormente, 37.246 archivos de ventanas temporales pareados (data/bordes), confirmando que reproducían la Tabla 1 del artículo original con exactitud a varios decimales, e identificando una limitación de cobertura: los archivos disponibles cubren ~1056 nodos para el tamaño de celda de 10 km, frente a los ~3837

reportados en el artículo posiblemente por cubrir un subconjunto del catálogo completo de 46 años.

- Se construyó en un notebook de Google Colab (GPU L4), un pipeline con seis secciones: preparación de datos, análisis exploratorio (EDA), y los tres modelos comparados bajo el mismo protocolo de evaluación (Top-1/Top-5/Top-10 accuracy, y desempeño por estrato de frecuencia del nodo).
- El EDA reveló una distribución de activación de nodos con forma de ley de potencia: el 50% de la actividad se concentra en apenas el 6% del vocabulario de nodos, con el nido sísmico de Bucaramanga como hub dominante, este hallazgo replica de forma independiente, el resultado geológico central del artículo base.
- Se estableció un baseline probabilístico (cadena de Markov de primer orden, con suavizado estadístico) como piso de comparación obligatorio, y se entrenaron un modelo de atención secuencial y un modelo GNN (implementado en PyTorch puro, sin dependencias externas de grafos) con regularización activa desde el diseño, dado el volumen limitado de datos disponibles.

Resultados o hallazgos

La comparación final de las tres familias de modelos, evaluadas sobre el mismo conjunto de prueba, arrojó lo siguiente:

Modelo	Top-1	Top-5	Top-10
Markov suavizado (baseline)	6.6 %	16.2 %	19.9 %
Atención (secuencial)	9.1 %	17.1 %	18.6 %
GNN (estructural)	9.7 %	17.0 %	18.2 %

Ningún modelo superó de forma general al baseline probabilístico en la métrica Top-10. Al desagregar por frecuencia del nodo, se observó que la mejora de los modelos de atención y GNN está concentrada casi exclusivamente en los nodos de alta frecuencia (los hubs ya conocidos, como el nido de Bucaramanga), mientras que en los estratos de frecuencia media y baja los tres modelos caen a 0% o cerca de 0%, evidencia de que el cuello de botella real del problema es el volumen de datos disponible por nodo, no la sofisticación de la arquitectura.

- El GNN, pese a incorporar información geográfica y estructural adicional, no superó al modelo de atención pura ya que ambos muestran el mismo patrón por estrato, reforzando que el límite es de datos y no de información disponible.
- La señal predictiva real que sí existe está concentrada en los hubs ya identificables con el modelo más simple; no se encontró evidencia de que la estructura de red aporte capacidad predictiva adicional sobre la cola larga de nodos poco frecuentes con los datos actualmente disponibles.
- Este es un resultado negativo pero metodológicamente válido, consistente con la literatura sísmológica, que reconoce que la predicción confiable de sismicidad a corto plazo sigue siendo un problema abierto.

Dificultades encontradas

- Discrepancia sin resolver entre el número de nodos reconstruible desde los archivos de ventanas temporales (~1056) y el reportado en la Tabla 1 del artículo original (~3837) para el mismo tamaño de celda.
- El volumen de datos disponible (mediana de 2 observaciones por nodo de origen) limitó severamente la capacidad de generalización de los modelos de atención y GNN sobre nodos poco frecuentes.
- Se detectó y corrigió, durante el análisis exploratorio, un caso de sobreajuste aparente al calcular la reducción de entropía condicional con dos pasos de historia, la cual es una métrica inicialmente prometedora resultó ser un artefacto de combinaciones con una sola observación.

Próximos pasos

- Revisar si el catálogo completo (46 años) puede reconstruirse para ampliar la cobertura de nodos, dado que esto podría cambiar sustancialmente los resultados en los estratos de frecuencia media y baja.
- Explorar técnicas de ponderación de clases o submuestreo para intentar mejorar la cobertura de nodos poco frecuentes sin sacrificar el desempeño ya logrado sobre los hubs dominantes.
- Repetir el entrenamiento de los modelos de atención y GNN con varias semillas aleatorias, dado que se observó variación no trivial en los resultados entre una corrida preliminar en CPU y la corrida final en GPU.

Reflexión personal

Este proyecto exigió primero construir, desde cero, una comprensión básica de sismología, como el qué es un sismo, cómo se mide, por qué Colombia es una zona sísmicamente compleja, todo esto antes de poder interpretar con criterio los resultados cuantitativos. Esa base resultó indispensable ya que permitió reconocer que el hub dominante encontrado de forma puramente estadística en los datos correspondía exactamente al nido sísmico de Bucaramanga descrito en la literatura, validando de forma independiente el fenómeno geológico. El hallazgo más valioso del proceso no fue una mejora de modelo, sino la disciplina de reportar honestamente un resultado negativo: ni la atención secuencial ni la estructura de grafos lograron superar de forma general a un modelo probabilístico simple y de identificar con evidencia que la causa es la escasez de datos (no una limitación de arquitectura) esto es en sí mismo, un resultado científicamente útil para orientar el trabajo futuro de esta línea de investigación.

Palabras clave

Red small-world:

Tipo de red compleja que combina un alto coeficiente de agrupamiento local (comunidades densamente conectadas) con una baja longitud de camino promedio entre nodos, gracias a la presencia de unos pocos nodos hub que actúan como puente entre comunidades.

Nido sísmico:

Zona geográfica que concentra una tasa de actividad sísmica anómalamente alta y relativamente aislada de la sismicidad circundante; el de Bucaramanga (~160 km de profundidad) es la mayor concentración de sismicidad de profundidad intermedia registrada en el mundo.

Cadena de Markov de primer orden:

Modelo probabilístico que estima la probabilidad del siguiente estado (nodo) únicamente a partir del estado actual, mediante conteo de frecuencias históricas de transición.

Red neuronal de grafos (GNN):

Arquitectura de aprendizaje profundo que actualiza la representación de cada nodo combinando su propia información con la de sus vecinos directos en la topología del grafo, antes de usarla para una tarea de predicción.

Partición temporal:

División de un conjunto de datos secuencial en entrenamiento, validación y prueba respetando estrictamente el orden cronológico, para evitar que el modelo tenga acceso a información del futuro durante el entrenamiento.

Referencias

- León-Vargas, D., Bucheli-Guerrero, V. A., y Ordoñez-Erazo, H. A. (2023). Modelado de la sismicidad colombiana como una red compleja espacio-secuencial. *Revista Científica*, 48(3), 67-81. <https://doi.org/10.14483/23448350.20963>

Material complementario

- Repositorio de código (GitHub): [\[Link\]](#)
- Notebook de Google Colab (preparación de datos, EDA y los tres modelos): [\[Link\]](#)
- Datos y resultados intermedios (Google Drive): [\[Link\]](#)